Projet DS - réaliser un score d'octroi pour le compte de RCI

March 26, 2020

```
[131]: #Etape 1
       import numpy as np
       import pandas as pd
       import matplotlib.pyplot as plt
       %matplotlib inline
       import seaborn as sns
       from sklearn.linear_model import LinearRegression
       from sklearn.feature_selection import VarianceThreshold
       from scipy import stats
       #Etape 2
       from sklearn.metrics import confusion_matrix
       from sklearn.model_selection import train_test_split, GridSearchCV
       from imblearn.over_sampling import SMOTE
       from sklearn.linear_model import LogisticRegression
       from sklearn.ensemble import GradientBoostingClassifier, RandomForestClassifier
       from sklearn.metrics import confusion_matrix, recall_score, precision_score,_
        →f1_score, roc_curve, roc_auc_score
       from scikitplot.metrics import plot_cumulative_gain, plot_precision_recall,_
       \hookrightarrowplot_confusion_matrix
       from sklearn import preprocessing
       import proj_func
```

```
d1 = pd.crosstab(df.loc[df['def12_31']=='0', name], df.
 \rightarrowloc[df['def12_31']=='0','def12_31'])
   d2 = round(pd.crosstab(df.loc[df['def12_31']=='0', name], df.
→loc[df['def12_31']=='0','def12_31'], normalize='columns'),2)*100
   d3 = pd.crosstab(df.loc[df['def12_31']=='1', name], df.
→loc[df['def12_31']=='1','def12_31'])
   d4 = round(pd.crosstab(df.loc[df['def12_31']=='1', name], df.
→loc[df['def12_31']=='1','def12_31'], normalize='columns'),2)*100
   df_tmp1 = pd.concat([d1,d2], axis=1, keys=['Effectif', 'Pourcentage'])
   df_tmp2 = pd.concat([d3,d4], axis=1, keys=['Effectif', 'Pourcentage'])
   display_side_by_side(df_tmp1, df_tmp2)
def comparer_2dist(name_var,df,x=0):
   df0 = df.loc[df['def12 31'] == '0',]
   df1 = df.loc[df['def12_31']=='1', ]
   fig, ax = plt.subplots()
   sns.distplot(df0[name_var], hist=False, rug=True, color='b')
   sns.distplot(df1[name_var], hist=False,rug=True, color='r')
   ax.legend(('0', '1'), loc='upper right')
   ax.set_xlabel(name_var)
   ax.axvline(x);
#SEVERAL LIFT CHART ON THE SAME PLOT
def plot cumulative gain(y true, y probas, title='Cumulative Gainsu
→Curve',ax=None, figsize=None, title_fontsize="large",text_fontsize="medium"):
    """Generates the Cumulative Gains Plot from labels and scores/probabilities
    The cumulative gains chart is used to determine the effectiveness of a
    binary classifier. A detailed explanation can be found at
    http://mlwiki.org/index.php/Cumulative_Gain_Chart. The implementation
   here works only for binary classification.
   Args:
        y_true (array-like, shape (n_samples)):
            Ground truth (correct) target values.
        y_probas (array-like, shape (n_samples, n_classes)):
            Prediction probabilities for each class returned by a classifier.
        title (string, optional): Title of the generated plot. Defaults to
            "Cumulative Gains Curve".
        ax (:class:`matplotlib.axes.Axes`, optional): The axes upon which to
            plot the learning curve. If None, the plot is drawn on a new set of
            axes.
        figsize (2-tuple, optional): Tuple denoting figure size of the plot
            e.g. (6, 6). Defaults to `None`.
        title_fontsize (string or int, optional): Matplotlib-style fontsizes.
            Use e.g. "small", "medium", "large" or integer-values. Defaults to
```

```
"large".
    text fontsize (string or int, optional): Matplotlib-style fontsizes.
        Use e.q. "small", "medium", "large" or integer-values. Defaults to
        "medium".
Returns:
    ax (:class:`matplotlib.axes.Axes`): The axes on which the plot was
Example:
    >>> import scikitplot as skplt
    >>> lr = LogisticRegression()
   >>> lr = lr.fit(X_train, y_train)
    >>> y_probas = lr.predict_proba(X_test)
    >>> skplt.metrics.plot_cumulative_gain(y_test, y_probas)
    <matplotlib.axes._subplots.AxesSubplot object at 0x7fe967d64490>
    >>> plt.show()
    .. image:: _static/examples/plot_cumulative_gain.png
       :align: center
       :alt: Cumulative Gains Plot
y_true = np.array(y_true)
y_probas = np.array(y_probas)
classes = np.unique(y_true)
if len(classes) != 2:
    raise ValueError('Cannot calculate Cumulative Gains for data with '
                     '{} category/ies'.format(len(classes)))
# Compute Cumulative Gain Curves
#percentages, gains1 = cumulative_gain_curve(y_true, y_probas[:, 0],
                                             classes[0])
percentages, gains2 = cumulative_gain_curve(y_true, y_probas[:, 1],
                                            classes[1])
if ax is None:
    fig, ax = plt.subplots(1, 1, figsize=figsize)
ax.set_title(title, fontsize=title_fontsize)
#ax.plot(percentages, gains1, lw=3, label='Class {}'.format(classes[0]))
ax.plot(percentages, gains2, lw=3, label='Class {}'.format(classes[1]))
ax.set_xlim([0.0, 1.0])
ax.set_ylim([0.0, 1.0])
ax.set_xlabel('Percentage of sample', fontsize=text_fontsize)
ax.set_ylabel('Gain', fontsize=text_fontsize)
ax.tick_params(labelsize=text_fontsize)
```

```
ax.grid('on')
    #ax.legend(loc='lower right', fontsize=text_fontsize)
    return ax
def plot_lifts(arg_models, parameters, x_train, x_test, y_train, y_test):
    arg_models = la liste de model que tu veux tester
    parameters = liste des paramètres à tester ex pour LR et GB :
    (['learning_rate', 'n_estimators'], ['penalty'])
    fig ,ax = plt.subplots()
    legend = []
    for count, model in enumerate(arg_models):
        s = type(model).__name__ #+ ' : '
        #for param in parameters[count]:
        # s += param + ' ' + str(model.get_params()[param]) + ', '
        \#s = s[:-2]
        x = {
            'label': s,
            'model': model,
        }
        legend.append(x['label'])
        x['model'].fit(x_train, y_train) # train the model
        y pred proba =x['model'].predict proba(x test) # predict the test data
        plot_cumulative_gain(y_test, y_pred_proba, ax = ax)
    ax.set title('Lift Chart')
    ax.set_ylabel('TPR')
    ax.legend(legend, loc= 'lower right')
    ax.plot([0, 1], [0, 1], 'k--', lw=2, label='Baseline')
    fig.savefig('comparaison_models.png', dpi=200)
#LIFT TABLE
def lift_table(clf, x_train, x_test, y_train, y_test,n=10):
    clf.fit(x_train, y_train)
    probas = clf.predict_proba(x_test)[:,1] #over_clf.classes_ #['0', '1']
    df = pd.DataFrame({'p':probas, 'y_test':y_test}).sort_values('p',__
 →ascending=False)
    tx_cible = len(y_test[y_test == 1])/len(y_test)
    1 = np.array_split(df, n, axis=0)
    dic = {'alpha': [], 'effectif':[], 'nb_positif': []}
    for i in range(n):
        df_tmp = 1[i]
        dic['alpha'].append(i*1/n+1/n)
        dic['effectif'].append(round(len(df)*1/n)) #effectif
        dic['nb_positif'].append(len(df_tmp[df_tmp['y_test']==1])) #effectif de_u
 \hookrightarrow 1
```

```
res = pd.DataFrame(dic)
    res['pc_positif'] = res['nb_positif']/res['effectif']*100
    res['alpha_lift'] = res['pc_positif']/100/tx_cible
    res['cum_effectif'] = np.cumsum(res['effectif'])
    res['cum_positif'] = np.cumsum(res['nb_positif'])
    res['cum_alpha_lift'] = (res['cum_positif']/res['cum_effectif'])/tx_cible
    return res
def feature_importance(clf, x_train, y_train):
    plot the 10 most important features
    clf.fit(x_train, y_train)
    importances = clf.feature_importances_
    df_tmp = pd.concat([pd.Series(importances), pd.Series(x_train.columns)],__
\rightarrowaxis=1)
    df_tmp = df_tmp.sort_values(0, ascending=False)
    fig, ax = plt.subplots()
    ax.barh(df_tmp.iloc[:10,1], df_tmp.iloc[:10,0])
    ax.set title('features importance')
def plot_ROCs(arg_models, x_train, x_test, y_train, y_test):
    plt.figure()
    # Below for loop iterates through your models list
    for count, model in enumerate(arg_models):
        s = type(model).__name__ #+ ' : '
        #for param in parameters[count]:
        # s += param + ' ' + str(model.get_params()[param]) + ', '
        #s = s[:-2]
        x = {
            'label': s,
            'model': model,
        }
        x['model'].fit(x_train, y_train) # train the model
        y_pred=x['model'].predict(x_test) # predict the test data
        # Compute False postive rate, and True positive rate
        fpr, tpr, thresholds = roc_curve(y_test, x['model'].
 →predict_proba(x_test)[:,1], pos_label = 1)
        # Calculate Area under the curve to display on the plot
        auc = roc_auc_score(y_test,model.predict(x_test))
        # Now, plot the computed values
        plt.plot(fpr, tpr, label='%s, AUC = \%.1f'\% (x['label'], ((auc + 0.
\rightarrow 2)*100)) + '%')
    # Custom settings for the plot
```

```
plt.plot([0, 1], [0, 1], 'r--')
           plt.xlim([0.0, 1.0])
           plt.ylim([0.0, 1.05])
           plt.xlabel('1-Specificity(FPR)')
           plt.ylabel('Sensitivity(TPR)')
           plt.title('Courbe ROC')
           plt.legend(loc="lower right")
           plt.savefig('ROC.png', dpi=200)
                         # Display
           plt.show()
[133]: raw_data = pd.read_csv('octroi_RCI.csv', sep = ';', decimal= ',', header=0,__
        →parse_dates=['mois_gestion'], dtype = {'STITUATION_FAM':'category', |
        → 'MODE_LOGT': 'category', 'VN_VO': 'category', 'MARQUE': 'category', 
        → 'anciennete_rci': 'category', 'def12_31': 'category'})
       df = raw data.copy()
       df = df.drop('mois_gestion', axis=1) #variable inutile
       raw_data.head() #(8457, 19)
[133]:
          ANC_EMPLOI STITUATION_FAM MODE_LOGT
                                                 AGE_VEH VN_VO MARQUE PRIX_VEH \
       0
                   65
                                    2
                                               1
                                                      NaN
                                                              VN
                                                                    REN
                                                                          19584.65
                  563
                                               2
                                                     28.0
       1
                                   11
                                                              VO
                                                                    REN
                                                                          16995.00
       2
                  107
                                    2
                                               2
                                                     16.0
                                                              VO
                                                                    REN
                                                                          19950.00
                                    2
       3
                  143
                                               2
                                                     10.0
                                                              VO
                                                                    REN
                                                                          17500.00
                                    2
                                                      7.0
                                                                          19740.00
                  110
                                             NaN
                                                              VO
                                                                    REN
          MT_APPORT
                      MT_FINANCE
                                   MT_MENS
                                             VR_BALLON DUREE_CONTRAT
                                                                         MT_PREST
                                              19584.63
       0
                 0.0
                        19584.65
                                     95.01
                                                                              {\tt NaN}
             2123.0
                        14872.00
                                    312.34
                                                                            150.0
       1
                                                   NaN
                                                                    60
       2
             3869.0
                        16081.00
                                    329.93
                                                                     60
                                                                            150.0
                                                   NaN
       3
             7143.5
                        10356.50
                                    217.51
                                                   NaN
                                                                     60
                                                                            150.0
             3789.4
                        15950.60
                                    310.33
                                               7523.04
                                                                     36
                                                                            150.0
          MT_ASSUR mois_gestion
                                   age_cli anciennete_rci pc_appo def12_31
       0
                      2015-01-03
                                        28
                                                                   0
               {\tt NaN}
                                                          1
                                                                             0
       1
               {\tt NaN}
                      2014-01-06
                                        64
                                                          3
                                                                  12
                                                                             0
       2
                                                          3
                                                                  19
                                                                             0
               {\tt NaN}
                      2015-01-08
                                        51
       3
                                        42
                                                          4
                                                                  41
                                                                             0
               NaN
                      2015-01-04
             395.0
                      2015-01-02
                                        34
                                                                  19
```

1 Etape 1 : Description du jeu de données

1.1 Description des variables

On dispose de 19 variables : VARIABLE / SEGMENT / TYPE / EXPECTATION

VARIABLE CIBLE - def12_31: indique si la personne a fait défaut 1=Oui / 0=Non. var. quali. 2mod

FEATURES

Client - age_cli: Age du client. N - ANC_EMPLOI : Ancienneté à l'emploi. N - STITUA-TION_FAM : Situation familiale. C (6 mods) (1=Marié, 2=Célib, 3=Divorcé, 4=Veuf, 5=Séparé, 11=Colloc) - MODE_LOGT : Mode de logement C (4 mods) (1=locataire, 2=proprio, 3=autre, 4=chez les parents) - anciennete_rci: Ancienneté relation rci. C (4 mods) - mois_gestion: Mois d'entrée en gestion. C

Contrat - pc_appo: Pourcentage d'apport. N - MT_APPORT : Montant de l'apport. N - MT_FINANCE : Montant financé. N - MT_MENS: Montant de la mensualité. N - VR_BALLON: Montant ballon. N - DUREE_CONTRAT: Durée du contrat. N - MT_PREST: Montant des prestations. N - MT_ASSUR: Montant des assurances. N

Véhicule - **PRIX_VEH** : Prix du véhicule. N - **AGE_VEH** : Age du véhicule. N - **MARQUE** : Marque. C - **VN_VO** : Type de véhicule. C (2 mods : VN=véhicule neuf /VO= véhicule occasion)

On s'attend à ce que les variables age du client, ancienneté à l'emploi, pourcentage d'apport / montant apport, durée du contrat et prix du véhicule soient les vars. les plus importantes.

1.2 Etude de la cible

```
[134]: Effectif Pourcentage col_0 count count def12_31 0 8359 99.0 1 98 1.0
```

Jeux de données extrêmement déséquilibré : 1% de taux de cible (98 individus). Il va donc être très difficile d'obtenir de bonnes performances compte tenu du jeu de données initial.

1.3 Valeurs manquantes

```
Percent
[135]:
                        Total
       anciennete_rci
                         7271
                                   86.0
       MT_ASSUR
                         6755
                                   79.9
       AGE_VEH
                         6003
                                   71.0
       VR_BALLON
                         5238
                                   61.9
       MT PREST
                          1280
                                   15.1
```

MODE_LOGT 108 1.3

```
[136]: #MT_ASSUR

df.loc[df['MT_ASSUR'] ==0] #on ne dispose d'aucune ligne dont le montant

dd = df.fillna(value={'MT_ASSUR':0}) #on peut imaginer remplacer les NaN par

des zéros

#AGE_VEH

df = df.fillna(value={'AGE_VEH':0}) #Les valeurs manquantes correspondent aux

véhicules neufs.

#VR_BALLON

df = df.fillna(value={'VR_BALLON':0}) #Les VM correspondent aux personnes qui

n'ont pas pris de crédit ballon

#MT_PREST

df = df.fillna(value={'MT_PREST':0}) #Les VM correspondent aux personnes qui

n'ont pas pris de préstations supplémentaires

[137]: #MODE_LOGT
```

round(pd.crosstab(df['MODE_LOGT'], df['STITUATION_FAM'], normalize = 'columns', __

TABLEAU PROFILS COLONNES

print('TABLEAU PROFILS COLONNES')

→margins=True, dropna=True),3)

[137]:	STITUATION_FAM MODE_LOGT	1	11	2	3	4	5	All
	1	0.102	0.353	0.212	0.223	0.026	0.305	0.137
	2	0.883	0.538	0.379	0.702	0.967	0.627	0.764
	3	0.004	0.058	0.013	0.008	0.000	0.017	0.008
	4	0.011	0.052	0.397	0.066	0.007	0.051	0.091

Rappel:

- situation fam (1=Marié, 2=Célib, 3=Divorcé, 4=Veuf, 5=Séparé, 11=Colloc)
- MODE_LOGT Mode de logement C (4 mods) (1=locataire, 2=proprio, 3=autre, 4=chez les parents) "

Retour sur la variable mode de logement :

- 1 (61 valeurs) : Parmi les gens mariés, 88% sont proprios
- 2 (36 valeurs) : Parmi les gens célibataires, c'est plus compliqué.. 1,2 ou 4...
- 4 (1 valeurs): Parmi les veufs, 96% sont proprios
- 5 (4 valeurs) : Parmi les séparés, env 60% proprios, 30% loc
- 11 (6 valeurs) : Parmi les colocs, env 55% sont proprios et 35% sont locataires

Il y 80% d'être proprio quand on est marié. On décide de remplacer les NA Mode Logt des mariés

par proprio et on se débarrasse des autres lignes.

Vérification après analyse des Valeurs Manquantes

```
[139]: df.isnull().sum().sort_values(ascending=False)
```

```
7271
[139]: anciennete_rci
       MODE\_LOGT
                             36
       def12_31
                              0
                              0
       MT_APPORT
       STITUATION_FAM
                              0
       AGE_VEH
                              0
       VN_VO
                              0
       MARQUE
                              0
       PRIX_VEH
                              0
       MT FINANCE
                              0
       pc_appo
                              0
       MT MENS
                              0
       VR BALLON
       DUREE CONTRAT
                              0
       MT_PREST
                              0
       MT_ASSUR
                              0
                              0
       age_cli
       ANC_EMPLOI
                              0
       dtype: int64
```

1.4 Analyse des vars. quantitatives

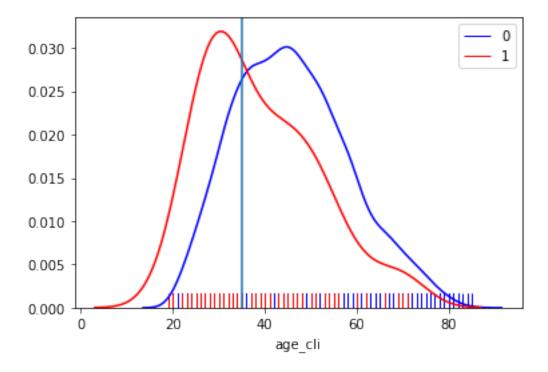
```
'DUREE_CONTRAT',
'MT_PREST',
'MT_ASSUR',
'age_cli',
'pc_appo']
```

Un exemple de la méthode utilisée :

On va se pencher sur chaque variable quantitative pour la discrétiser pour ensuite transformer l'intégralité de nos variables en dummies. L'idée est de créer des classes qui permettent de discriminer les deux groupes. On doit aussi s'assurer que chaque classe est suffisamment grande (> à 5 obs.)

Essayons d'illuster notre propos avec la variable "age du client":





On observe que une queue de distribution à droite pour les gens qui ne font pas défaut, à gauche pour les gens qui font défaut. La variable Age permet de discriminer les 2 groupes

```
[142]: df['age_cli_CAT'] = pd.cut(df['age_cli'], precision=0, bins= 3)
[143]: comparer_cible('age_cli_CAT')
[144]: #ANC_EMPLOI
    df['ANC_EMPLOI'] = df['ANC_EMPLOI']/12
```

```
df['ANC_EMPLOI_CAT'] = 0
df.loc[(df['ANC_EMPLOI']<=5), ['ANC_EMPLOI_CAT']] = '(0, 5]'</pre>
df.loc[(df['ANC_EMPLOI']>5) & (df['ANC_EMPLOI']<=10), ['ANC_EMPLOI_CAT']] =
df.loc[(df['ANC_EMPLOI']>10) & (df['ANC_EMPLOI']<=20), ['ANC_EMPLOI_CAT']] = 
\hookrightarrow '(10, 20]'
df.loc[(df['ANC_EMPLOI']>20), ['ANC_EMPLOI_CAT']] = '(20, .]'
#AGE_VEH
df['AGE VEH CAT'] = 0
df.loc[(df['AGE_VEH']==0), ['AGE_VEH_CAT']] = '0'
df.loc[(df['AGE VEH']>0) & (df['AGE VEH']<=40), ['AGE VEH CAT']] = '(0,40]'
df.loc[(df['AGE_VEH']>40), ['AGE_VEH_CAT']] = '(40,.]'
#PRIX VEH
df['PRIX_VEH_CAT'] = 0
df.loc[(df['PRIX VEH']<=13000), ['PRIX VEH CAT']] = '(0,13000]'</pre>
df.loc[(df['PRIX_VEH']>13000), ['PRIX_VEH_CAT']] = '(13000,.]'
#MT_APPORT
df['MT APPORT CAT'] = 0
df.loc[(df['MT_APPORT']<=3000), ['MT_APPORT_CAT']] = '(0,3000]'</pre>
df.loc[(df['MT_APPORT']>3000), ['MT_APPORT_CAT']] = '(3000,.]'
#pc_apport
df['pc_appo_CAT'] = 0
df.loc[df['pc_appo'] <= 22, ['pc_appo_CAT']] = '(0, 22]'</pre>
df.loc[(df['pc_appo']>22), ['pc_appo_CAT']] = '(22, .]'
#MT FINANCE
df['MT_FINANCE_CAT']=0
df.loc[(df['MT FINANCE']<=9000), ['MT FINANCE CAT']] = '(0,9000]'</pre>
df.loc[(df['MT_FINANCE']>9000) & (df['MT_FINANCE']<=12000), ['MT_FINANCE_CAT']]
\Rightarrow= '(9000,12000]'
df.loc[(df['MT_FINANCE']>12000), ['MT_FINANCE_CAT']] = '(12000,.]'
#VR_BALLON
df['VR BALLON CAT'] = 0
df.loc[(df['VR BALLON']==0), ['VR BALLON CAT']] = '0'
df.loc[(df['VR BALLON']>0), ['VR BALLON CAT']] = '>0'
#DUREE CONTRAT
df['DUREE_CONTRAT_CAT'] = 0
df.loc[(df['DUREE CONTRAT']<=30), ['DUREE CONTRAT CAT']] = '(0,30]'</pre>
df.loc[(df['DUREE_CONTRAT']>30) & (df['DUREE_CONTRAT']<=40),__</pre>
\hookrightarrow ['DUREE_CONTRAT_CAT']] = '(30, 40]'
df.loc[(df['DUREE_CONTRAT']>40), ['DUREE_CONTRAT_CAT']] = '(40,.]'
```

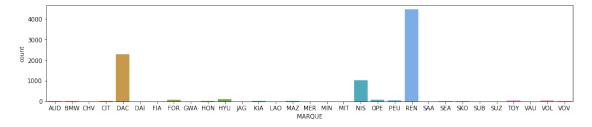
```
#MT_PREST
df['MT_PREST_CAT'] = 0
df.loc[(df['MT_PREST']==150), ['MT_PREST_CAT']] = '150'
df.loc[(df['MT_PREST']!=150), ['MT_PREST_CAT']] = 'autre'

#MT_ASSUR
df['MT_ASSUR_CAT'] = 0
df.loc[(df['MT_ASSUR']==0), ['MT_ASSUR_CAT']] = '0'
df.loc[(df['MT_ASSUR']>0), ['MT_ASSUR_CAT']] = '>0'

#MT_MENS
df['MT_MENS_CAT'] = 250
df.loc[(df['MT_MENS']<250), ['MT_MENS_CAT']] = '(0,250]'
df.loc[(df['MT_MENS']>=250), ['MT_MENS_CAT']] = '(250,.]'
```

1.5 Analyse des variables qualitatives

Cette fois-ci les variables considérée sont déjà catégorielles. Il n'est pas nécessaire de créer des classes. En revanche il faut s'assurer que chaque modalité est pertinente, c'est à dire que chaque modalité présente plus de 5 individus. On va réarranger nos variables catégorielles en ce sens



On réduit le nombre de modalité à 2 : 'groupe renault' et 'autre'.

```
[146]: df['MARQUE_CAT'] =0
```

```
[147]: #On se débarasse de l'ancienne variable Marque df = df.drop(['MARQUE'], axis=1)
```

1.6 Feature Engeneering

Pour améliorer les performances de notre modèle, on créer de nouvelles variables. Il s'agit essentiellement de variables métier et de ratio qui nous ont semblés intéressants.

```
#PRIX_TOTAL

df = df.assign(PRIX_TOTAL = df['PRIX_VEH']+df['MT_APPORT']+df['MT_PREST'] +

df['VR_BALLON']+df['MT_ASSUR'])

#MENS_par_FINANCE

df = df.assign(MENS_par_FINANCE= df['MT_MENS']/df['MT_FINANCE'])

#PREST_par_FINANCE

df = df.assign(PREST_par_FINANCE= df['MT_PREST']/df['MT_FINANCE'])

#ASSUR_par_FINANCE

df = df.assign(ASSUR_par_FINANCE= df['MT_ASSUR']/df['MT_FINANCE'])

#age_cli_par_DUREE

df = df.assign(age_cli_par_DUREE= df['age_cli']/df['DUREE_CONTRAT'])

#DUREE_C_par_FINANCE

df = df.assign(DUREE_C_par_FINANCE= df['DUREE_CONTRAT']/df['MT_FINANCE'])
```

```
[149]: #On transforme ces variables en vars. quali
eng_feats = ['PRIX_TOTAL', 'MENS_par_FINANCE', 'DUREE_C_par_FINANCE', \
'PREST_par_FINANCE', 'ASSUR_par_FINANCE', 'age_cli_par_DUREE']
cat_feats = list(df.dtypes[df.dtypes == 'object'].index)
for col in cat_feats:
    df[col] = df[col].astype('category',copy=False)

#On se débarasse des précédentes vars. quali
#old_cat_feats = ['ANC_EMPLOI', 'AGE_VEH', 'PRIX_VEH', 'MT_APPORT', 'pc_appo', \
\( \times 'MT_FINANCE', \\
\( \times 'VR_BALLON', 'DUREE_CONTRAT', 'MT_PREST', 'MT_ASSUR', 'MT_MENS', \) \( \times 'STITUATION_FAM', 'MARQUE']
#df = df.drop(old_cat_feats, axis=1)
```

1.7 Vérification et transformation en dummies

```
[150]: df.info()
       df.shape \#(8457, 38)
      <class 'pandas.core.frame.DataFrame'>
      RangeIndex: 8457 entries, 0 to 8456
      Data columns (total 37 columns):
      ANC EMPLOI
                              8457 non-null float64
      STITUATION_FAM
                              8457 non-null category
      MODE_LOGT
                              8421 non-null category
      AGE_VEH
                              8457 non-null float64
      VN_VO
                              8457 non-null category
      PRIX_VEH
                              8457 non-null float64
                              8457 non-null float64
      MT_APPORT
      MT_FINANCE
                              8457 non-null float64
      MT_MENS
                              8457 non-null float64
                              8457 non-null float64
      VR BALLON
      DUREE_CONTRAT
                              8457 non-null int64
      MT PREST
                              8457 non-null float64
      MT_ASSUR
                              8457 non-null float64
      age_cli
                              8457 non-null int64
                              1186 non-null category
      anciennete_rci
                              8457 non-null int64
      pc_appo
      def12_31
                              8457 non-null category
                              8457 non-null category
      age_cli_CAT
      ANC_EMPLOI_CAT
                              8457 non-null category
                              8457 non-null category
      AGE_VEH_CAT
      PRIX_VEH_CAT
                              8457 non-null category
      MT_APPORT_CAT
                              8457 non-null category
                              8457 non-null category
      pc_appo_CAT
      MT_FINANCE_CAT
                              8457 non-null category
                              8457 non-null category
      VR_BALLON_CAT
      DUREE_CONTRAT_CAT
                              8457 non-null category
      MT_PREST_CAT
                              8457 non-null category
      MT_ASSUR_CAT
                              8457 non-null category
      MT_MENS_CAT
                              8457 non-null category
      STITUATION_FAM_CAT
                              8457 non-null category
      MARQUE_CAT
                              8457 non-null category
      PRIX_TOTAL
                              8457 non-null float64
                              8457 non-null float64
      MENS_par_FINANCE
                              8457 non-null float64
      PREST_par_FINANCE
                              8457 non-null float64
      ASSUR_par_FINANCE
      age_cli_par_DUREE
                              8457 non-null float64
      DUREE_C_par_FINANCE
                              8457 non-null float64
      dtypes: category(19), float64(15), int64(3)
      memory usage: 1.3 MB
```

```
[150]: (8457, 37)
[151]: df = df.drop('def12_31', axis=1)
       df = pd.get_dummies(df)
[152]: #vérification
       df.shape
[152]: (8457, 71)
[153]: np.where(df.isna())
       df.isna().sum(axis=0).sort_values(ascending=False)
[153]: MARQUE CAT groupe renault
                                      0
       {\tt MODE\_LOGT\_2}
                                      0
       STITUATION_FAM_11
                                      0
       STITUATION_FAM_2
                                      0
       STITUATION_FAM_3
                                      0
       MT_APPORT_CAT_(0,3000]
                                     0
       MT_APPORT_CAT_(3000,.]
                                      0
       pc_appo_CAT_(0, 22]
                                      0
                                      0
       pc_appo_CAT_(22, .]
       ANC_EMPLOI
                                      0
       Length: 71, dtype: int64
```

2 Etape 2:

2.1 Cross-validation stratifiée :

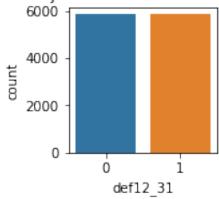
On sépare notre jeu de données initiale en un jeu d'entrainement (train set) et un jeu de validation (test set). Il est crucial d'avoir le même taux de cible dans les 2 jeux de données (~1%)

2.2 Rééchantillonnage : méthode SMOTE

Le but de cette méthode de sur-échantillonnage est de créer artificiellement des données de la classe '1' à partir des 98 individus qui font défaut.

(11700, 71)

Répartition des Défauts et non défauts dans le jeu de données d'entrainement



2.3 Standardisation des données

```
[157]: #On s'assure que les données soient dans le bon format
y_resampled = y_resampled.astype('uint8')
y_train = y_train.astype('uint8')
y_test = y_test.astype('uint8')
```

2.4 1er modèle : Régression Logistique

```
[158]: params = {
          'penalty':('12', 'none'),
          'C': (0.001, 0.01, 0.1),
          'solver': ['newton-cg', 'lbfgs', 'sag'],
          'l1_ratio': np.arange(0.1,0.9,0.1),
```

```
lr_clf = GridSearchCV(
    estimator = LogisticRegression(max_iter=10000),
    param_grid = params,
    cv = 5, #specify the number of folds in a (Stratified)KFold
    scoring =['precision', 'recall', 'f1'],
    refit = 'f1',
    n_jobs = -1, #1 pas de parallélisation / -1 parallélisation
    verbose=1
    )

#lr_clf.fit(X_sc_resampled, y_resampled)
```

On obtient notre meilleur classifier pour la régression logistique :

```
[159]: | lr_clf = LogisticRegression(penalty='11', solver='liblinear', C=0.01)
[160]: table_lift = lift_table(lr_clf, X_sc_resampled, X_sc_test, y_resampled, y_test)
       table_lift
[160]:
          alpha effectif nb_positif pc_positif
                                                     alpha_lift cum_effectif \
            0.1
                       254
                                    11
                                           4.330709
                                                       3.790117
                                                                            254
                                     5
       1
            0.2
                       254
                                           1.968504
                                                       1.722780
                                                                           508
       2
            0.3
                       254
                                     2
                                                       0.689112
                                                                           762
                                           0.787402
       3
            0.4
                       254
                                     2
                                           0.787402
                                                       0.689112
                                                                           1016
       4
            0.5
                       254
                                     4
                                           1.574803
                                                       1.378224
                                                                           1270
       5
            0.6
                       254
                                     2
                                           0.787402
                                                       0.689112
                                                                           1524
       6
            0.7
                       254
                                     2
                                           0.787402
                                                       0.689112
                                                                           1778
       7
                       254
            0.8
                                     1
                                           0.393701
                                                       0.344556
                                                                           2032
       8
            0.9
                       254
                                     0
                                           0.000000
                                                       0.000000
                                                                           2286
            1.0
                       254
                                           0.000000
                                                       0.000000
                                                                           2540
          cum_positif
                       cum_alpha_lift
       0
                              3.790117
                   11
       1
                    16
                              2.756449
       2
                    18
                              2.067336
       3
                   20
                              1.722780
       4
                   24
                              1.653869
       5
                   26
                              1.493076
       6
                   28
                              1.378224
       7
                   29
                              1.249016
                   29
       8
                              1.110236
       9
                    29
                              0.999213
```

3 Etape 3 : Modèles ensemblistes : Boosting & Random Forest

3.1 Boosting

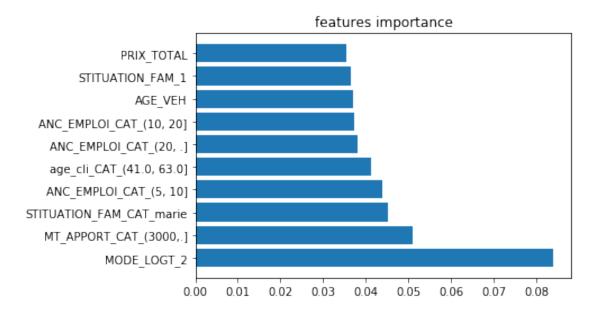
29

Le boosting dans cet exemple donne de mauvais résultats. On ne s'attardera donc pas sur cet algorithme.

```
[161]: gb_clf = GradientBoostingClassifier(learning_rate = 0.01, n_estimators= 1500,__
        →max_depth=4, min_samples_split=2, min_samples_leaf=1,
                                         subsample=1, max_features='sqrt')
       lift_table(gb_clf, X_sc_resampled, X_sc_test, y_resampled, y_test)
                             nb_positif
[161]:
                                                       alpha_lift
          alpha
                  effectif
                                          pc_positif
                                                                    cum_effectif
                                            1.181102
             0.1
                       254
                                      3
                                                         1.033668
                                                                              254
       0
             0.2
                       254
                                      7
                                            2.755906
                                                         2.411892
       1
                                                                             508
       2
             0.3
                       254
                                      5
                                            1.968504
                                                         1.722780
                                                                             762
       3
             0.4
                       254
                                      2
                                            0.787402
                                                         0.689112
                                                                            1016
       4
             0.5
                       254
                                      4
                                            1.574803
                                                         1.378224
                                                                            1270
       5
             0.6
                       254
                                      2
                                            0.787402
                                                         0.689112
                                                                            1524
       6
             0.7
                       254
                                      0
                                            0.000000
                                                         0.000000
                                                                            1778
       7
                       254
             0.8
                                      4
                                            1.574803
                                                         1.378224
                                                                            2032
       8
             0.9
                       254
                                      1
                                            0.393701
                                                         0.344556
                                                                            2286
       9
             1.0
                       254
                                            0.393701
                                                         0.344556
                                                                            2540
          cum_positif
                        cum_alpha_lift
       0
                     3
                               1.033668
       1
                    10
                               1.722780
       2
                    15
                               1.722780
       3
                    17
                               1.464363
       4
                    21
                               1.447135
       5
                    23
                               1.320798
       6
                    23
                               1.132113
       7
                    27
                               1.162877
       8
                    28
                               1.071952
```

```
[162]: feature_importance(gb_clf, X_sc_resampled, y_resampled)
```

0.999213



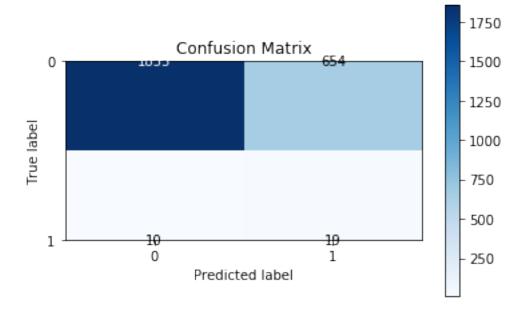
3.2 Random Forest

```
[163]: #GridSearch
       param_grid = {
           #'bootstrap': [True, False],
           'n_estimators': [200, 400, 600],
           'max_features': ['auto','sqrt'],
           \max_{depth'} : [2,3,4,5,6],
           'criterion' :['gini', 'entropy']
       }
       rf_clf = GridSearchCV(estimator= RandomForestClassifier(random_state=1),
                             param_grid=param_grid,
                             cv=5,
                             verbose = 5,
                             scoring = ('precision', 'recall', 'f1'),
                             refit = 'f1',
                             n jobs = -1)
       ##à dé-commenter si vous souhaitez lancer le gridsearch
       \#rf\_clf.fit(X\_sc\_resampled, y\_resampled)
       #res = pd.DataFrame(rf_clf.cv_results_)
       #feats = ['param_criterion', 'param_max_depth',_
       'mean\_test\_precision', 'mean\_test\_recall', 'mean\_test\_f1', \sqcup
       \hookrightarrow 'rank_test_f1']
```

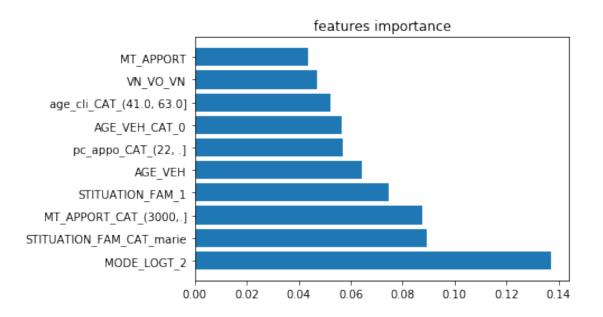
```
\#res[feats].sort\_values('rank\_test\_f1').head(5)
```

On obtient notre meilleur classifier pour le random Forest :

```
[165]: plot_confusion_matrix(y_test, y_pred);
```



```
[166]: feature_importance(rf_clf, X_sc_resampled, y_resampled)
```



[167]:	table_lift = lift_table(rf_clf, X_sc_resampled, X_sc_test, y_resampled, y_test)	
	table_lift	

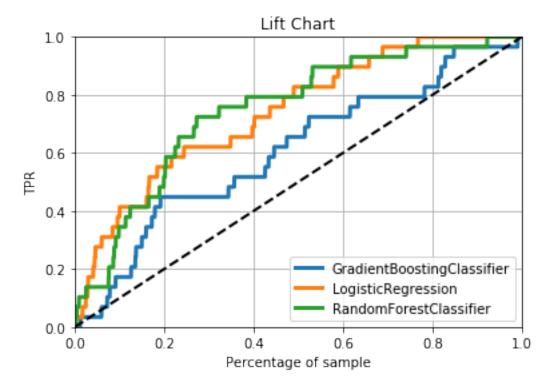
[167]:	alpha	effectif	nb_positif	pc_positif	alpha_lift	cum_effectif	\
0	0.1	254	10	3.937008	3.445561	254	
1	0.2	254	5	1.968504	1.722780	508	
2	0.3	254	6	2.362205	2.067336	762	
3	0.4	254	2	0.787402	0.689112	1016	
4	0.5	254	0	0.000000	0.000000	1270	
5	0.6	254	3	1.181102	1.033668	1524	
6	0.7	254	1	0.393701	0.344556	1778	
7	0.8	254	1	0.393701	0.344556	2032	
8	0.9	254	0	0.000000	0.000000	2286	
9	1.0	254	1	0.393701	0.344556	2540	

	cum_positif	cum_alpha_lift
0	10	3.445561
1	15	2.584171
2	21	2.411892
3	23	1.981197
4	23	1.584958
5	26	1.493076
6	27	1.329002
7	28	1.205946
8	28	1.071952
9	29	0.999213

3.3 Meilleur modèle et performances finales

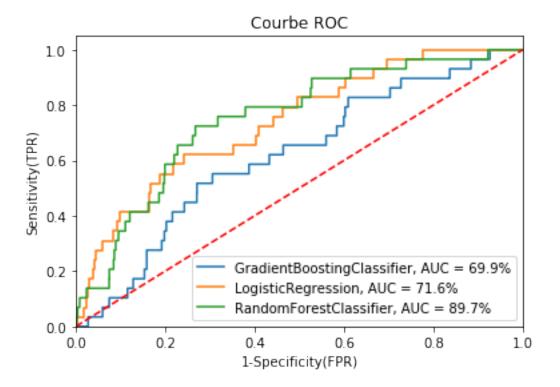
3.3.1 Courbes Lifts:

```
[168]: arg_models = [
           #Meilleur GB
           GradientBoostingClassifier(learning_rate = 0.05, n_estimators= 250, __
        →max_depth=4, min_samples_split=2, min_samples_leaf=1,
                                      subsample=1, max_features='sqrt'),
           #Meilleur LR
           LogisticRegression(penalty='l1', solver='liblinear', C=10),
           #Meilleur RF
           RandomForestClassifier(n_estimators= 600,
                                  max_features='sqrt',
                                  max_depth=2,
                                  criterion='gini',
                                  random_state=1)
       ]
       plot_lifts(arg_models,([], \
       [], []), X_sc_resampled, X_sc_test, y_resampled, y_test)
```



3.3.2 Courbes ROCs et AUC:

[169]: plot_ROCs(arg_models, X_sc_resampled, X_sc_test, y_resampled, y_test)



<Figure size 432x288 with 0 Axes>